

28 - Trabalho Final do Bootcamp: Sistema de Recomendação Inteligente de Jogos para Plataformas Digitais

Ronny Gabryel Colatino de Souza

Introdução:

O objetivo deste projeto foi desenvolver um sistema de recomendação de jogos digitais, aplicando os conceitos de aprendizado de máquina estudados ao longo do bootcamp em um problema real, a sobrecarga de escolha enfrentada por usuários de plataformas com catálogos extensos, como a Steam. Utilizei filtragem colaborativa baseada no histórico de horas jogadas, com o algoritmo SVD, Decomposição em Valores Singulares, como modelo principal, e o KNN Baseline como modelo de referência para comparação.

Desenvolvimento:

Definição do Problema

Plataformas digitais como a Steam concentram hoje dezenas de milhares de jogos, e esse volume de opções gerou um problema conhecido como sobrecarga de escolha. O usuário passa mais tempo procurando algo interessante do que efetivamente jogando, o que prejudica a experiência dele e a retenção dentro da plataforma.

O maior desafio deste projeto não estava apenas em aplicar um algoritmo de recomendação já conhecido, mas em transformar um dado implícito, o tempo de uso registrado, em uma métrica de engajamento capaz de alimentar o modelo de forma consistente. O dataset utilizado não possui nenhuma avaliação explícita dos usuários, apenas o comportamento de consumo, o que exigiu uma etapa adicional de tratamento antes de qualquer modelagem.

Base de Dados

Plataformas digitais como a Steam concentram hoje dezenas de milhares de jogos, e esse volume de opções gerou um problema conhecido como sobrecarga de escolha. O usuário passa mais tempo procurando algo

interessante do que efetivamente jogando, o que prejudica a experiência dele e a retenção dentro da plataforma.


O maior desafio deste projeto não estava apenas em aplicar um algoritmo de recomendação já conhecido, mas em transformar um dado implícito, o tempo de uso registrado, em uma métrica de engajamento capaz de alimentar o modelo de forma consistente. O dataset utilizado não possui nenhuma avaliação explícita dos usuários, apenas o comportamento de consumo, o que exigiu uma etapa adicional de tratamento antes de qualquer modelagem.

Abaixo, uma amostra das primeiras linhas do dataset bruto, ainda sem qualquer tratamento:

	Standard	Standard	Standard	Standard	Standard
1	151603712	The Elder Scrolls V Skyrim	purchase	1.0	0
2	151603712	The Elder Scrolls V Skyrim	play	273.0	0
3	151603712	Fallout 4	purchase	1.0	0
4	151603712	Fallout 4	play	87.0	0
5	151603712	Spore	purchase	1.0	0
6	151603712	Spore	play	14.9	0
7	151603712	Fallout New Vegas	purchase	1.0	0
8	151603712	Fallout New Vegas	play	12.1	0
9	151603712	Left 4 Dead 2	purchase	1.0	0
10	151603712	Left 4 Dead 2	play	8.9	0
11	151603712	HuniePop	purchase	1.0	0
12	151603712	HuniePop	play	8.5	0
13	151603712	Path of Exile	purchase	1.0	0
14	151603712	Path of Exile	play	8.1	0
15	151603712	Poly Bridge	purchase	1.0	0
16	151603712	Poly Bridge	play	7.5	0
17	151603712	Left 4 Dead	purchase	1.0	0
18	151603712	Left 4 Dead	play	3.3	0
19	151603712	Team Fortress 2	purchase	1.0	0
20	151603712	Team Fortress 2	play	2.8	0
21	151603712	Tomb Raider	purchase	1.0	0
22	151603712	Tomb Raider	play	2.5	0
23	151603712	The Banner Saga	purchase	1.0	0
24	151603712	The Banner Saga	play	2.0	0
25	151603712	Dead Island Epidemic	purchase	1.0	0
26	151603712	Dead Island Epidemic	play	1.4	0

Após as etapas de pré processamento, a base final ficou composta por 50.653 registros, referentes a 2.435 usuários e 1.011 jogos distintos, resultando em uma matriz usuário jogo com densidade de 2,06% e esparsidade de 97,94%, característica esperada em sistemas de

recomendação que lidam com catálogos extensos.



Metodologia

Pré Processamento

O dataset original apresenta dois tipos de registro quanto ao comportamento do usuário, compra e jogo. Como os registros de compra possuem um valor fixo de horas e não representam engajamento real, mantive apenas os registros referentes ao comportamento de jogo.

Em seguida, apliquei um filtro de esparsidade em duas frentes. Usuários com histórico inferior a cinco jogos foram descartados, por gerarem vetores de preferência pouco informativos, e jogos com menos de dez interações registradas também foram removidos, por não oferecerem sinal estatístico suficiente para que o modelo aprendesse algum padrão consistente. Após esse tratamento, a base saiu de duzentos mil registros brutos para 50.653 registros filtrados.

Construção da Métrica de Engajamento



A principal decisão metodológica do projeto foi definir como converter horas jogadas em uma escala discreta de engajamento, de um a cinco, compatível com o formato de entrada exigido por algoritmos de filtragem colaborativa baseados em notas.


Uma primeira abordagem, baseada em limiares fixos de horas, como classificar arbitrariamente menos de uma hora como nota mínima, foi descartada por ignorar diferenças estruturais entre gêneros de jogos. Vinte horas em um jogo de RPG podem representar um engajamento apenas mediano, enquanto o mesmo tempo em um jogo casual pode indicar saturação total da experiência.

Para resolver essa limitação, optei por uma normalização por percentil, calculada de forma independente para cada título. A posição percentil das horas jogadas por um usuário, em relação à distribuição de horas de todos os jogadores daquele mesmo jogo, determina sua nota de engajamento, seguindo os limiares de vinte, quarenta, sessenta e oitenta por cento. Dessa forma, a escala passa a refletir o comportamento relativo dentro da comunidade de jogadores de cada título, em vez de um valor absoluto de tempo.

Um cuidado metodológico importante foi tomado para evitar vazamento de dados entre treino e teste. Os limiares percentuais foram calculados exclusivamente a partir do conjunto de treino, correspondente a oitenta por cento dos dados, e posteriormente aplicados ao conjunto de teste, correspondente aos vinte por cento restantes, sem qualquer recomputação. Isso garantiu que a divisão entre treino e teste refletisse um cenário realista de avaliação, sem contaminação entre as duas partes.

O resultado dessa transformação foi uma distribuição praticamente uniforme entre as cinco classes de engajamento, conforme mostrado:





Modelos Utilizados

Avaliei dois algoritmos de filtragem colaborativa, ambos implementados por meio da biblioteca Surprise.

O primeiro foi o SVD, modelo principal do projeto, que fatora a matriz usuário jogo em fatores latentes, capturando padrões implícitos de preferência que não estão explícitos nos dados observados. O segundo foi o KNN Baseline, utilizado como modelo de referência, que combina efeitos de baseline com similaridade entre usuários, estimada por meio da técnica ALS e calculada através da correlação de Pearson.

Validação

A avaliação dos modelos seguiu duas estratégias. A primeira foi uma divisão simples entre treino e teste, na proporção de oitenta por cento e vinte por cento, com semente fixa para garantir a reprodutibilidade dos resultados. A segunda foi uma validação cruzada com cinco divisões, aplicada ao modelo SVD sobre a base completa, com o objetivo de verificar a estabilidade do

desempenho entre diferentes partições dos dados e reduzir o risco de conclusões enviesadas por uma única divisão específica.

As métricas de avaliação adotadas foram o RMSE e o MAE, para mensurar o erro de predição da nota de engajamento, e o Hit Rate arroba dez, para avaliar a utilidade prática das recomendações geradas.

O cálculo do Hit Rate arroba dez foi implementado considerando o catálogo completo de jogos, e não apenas o conjunto de teste isolado, de modo a simular de forma mais realista um cenário de produção. Para cada usuário, os jogos já conhecidos no treino foram excluídos do ranqueamento, e verifiquei se algum jogo relevante do conjunto de teste, com nota de engajamento igual ou superior a três, aparecia entre as dez recomendações com maior previsão de engajamento.

Resultados

Na validação cruzada com cinco divisões, o modelo SVD apresentou RMSE médio de 1,4341, com desvio padrão de 0,0069, e MAE médio de 1,2276, com desvio padrão de 0,0068. O desvio padrão reduzido observado nas duas métricas indica que o modelo generaliza de forma consistente entre diferentes partições da base.

```
Estadísticas da matriz usuário-jogo:
Usuários:2435
Jogos:1011
Interações:50653
Densidade:2.0576%
Esparsidade:97.9424%
Validação Cruzada SVD
RMSE médio: 1.4328 (0.0059)
MAE médio: 1.2289 (0.0059)
```

No conjunto de teste, o comparativo entre os dois algoritmos mostrou desempenho superior do SVD em ambas as métricas de erro, conforme a tabela a seguir.

Modelo	RMSE	MAE	Melhor RMSE	Melhor MAE
KNN	1,4559	1,2301	Não	Não

Baseline				
SVD	1,4206	1,2179	Sim	Sim

O modelo SVD foi selecionado como modelo final por apresentar o menor RMSE entre os dois algoritmos avaliados

```
Done computing similarity matrix.
KNN Baseline Avaliação no Conjunto de Teste
RMSE: 1.4559
MAE: 1.2301
SVD Avaliação no Conjunto de Teste
RMSE: 1.4206
MAE: 1.2179
```

Em relação ao Hit Rate arroba dez, calculado sobre o catálogo completo de jogos, o modelo SVD alcançou 15,53%, ou seja, para 15,53% dos usuários avaliados, pelo menos um jogo genuinamente relevante apareceu entre as dez primeiras recomendações geradas, considerando apenas jogos que o usuário ainda não conhecia. Esse resultado superou a meta estabelecida de acima de quinze por cento, ainda que por uma margem pequena.

Como demonstração prática, o sistema gerou a seguinte lista de recomendações para o usuário de identificador 54999247:

```
Modelo selecionado para recomendação final: SVD menor RMSE
Hit Rate@10 catálogo completo: 0.1553 (15.5%)
Top 10 recomendações para o usuário 54999247:
```

1. Grand Theft Auto Vice City	engajamento previsto: 3.58
2. Fallout 3	engajamento previsto: 3.56
3. DiRT 3	engajamento previsto: 3.55
4. Jamestown	engajamento previsto: 3.53
5. Grand Theft Auto V	engajamento previsto: 3.52
6. The Elder Scrolls V Skyrim	engajamento previsto: 3.51
7. PAYDAY 2	engajamento previsto: 3.49
8. Ultra Street Fighter IV	engajamento previsto: 3.48
9. Left 4 Dead	engajamento previsto: 3.48
10. LIMBO	engajamento previsto: 3.47

É importante destacar que os valores absolutos de RMSE e MAE obtidos são naturalmente mais elevados do que os observados em projetos que utilizam esquemas de limiar fixo. Isso ocorre porque a normalização por percentil maximiza a variância dos rótulos ao produzir uma distribuição uniforme entre as classes, tornando a tarefa de predição mais exigente. Por esse motivo, considero o Hit Rate arropa dez o indicador mais representativo da utilidade prática do sistema, ainda que o resultado tenha superado a meta por uma margem estreita, o que indica espaço para refinamento futuro do modelo.

Conclusão

Este projeto demonstrou ser possível construir um sistema de recomendação funcional e robusto utilizando exclusivamente o histórico de horas jogadas como sinal de engajamento, sem depender de avaliações explícitas fornecidas pelos usuários. A substituição de limiares fixos pela normalização percentil por jogo representou a principal contribuição metodológica deste trabalho, produzindo uma escala de engajamento mais fiel ao comportamento relativo de cada jogador. O modelo SVD, escolhido como solução final, apresentou desempenho superior ao KNN Baseline em todas as métricas avaliadas e gerou recomendações coerentes com o perfil individual de cada usuário, validando a abordagem proposta para o problema de sobrecarga de escolha em plataformas digitais de jogos.

Referências e Documentação

 scikit-surprise	https://surprise.readthedocs.io/en/stable/
 Pandas	https://pandas.pydata.org/docs/
 NumPy	https://numpy.org/doc/
Matplotlib	https://matplotlib.org/stable/index.html
 Seaborn	https://seaborn.pydata.org/

 Scikit-Learn	https://scikit-learn.org/stable/
--	---

- **Fonte:**
<https://www.kaggle.com/datasets/tamber/steam-video-games>
- **Tamanho Bruto: 200.000 registros**
- **Colunas: user_id, game_title, behavior, hours_played**